

KHOÁ LUẬN TỐT NGHIỆP NGÀNH CÔNG NGHỆ THÔNG TIN

Tên đề tài: Nghiên cứu, xây dựng hệ thống hỗ trợ ra quyết định tích hợp Trí tuệ nhân tạo có thể giải thích (XAI) và đánh giá tác động đến Thiên kiến tự động hóa.

Tên tiếng Anh: *Investigating the Effects of Explainable AI (XAI) Interfaces on Alleviating Automation Bias in Human Decision-Making.*

Định hướng ứng dụng: Hệ thống Đánh giá & Duyệt Tín dụng Ngân hàng (Credit Risk Assessment System).

CHƯƠNG 1: TỔNG QUAN VÀ TÍNH CẤP THIẾT CỦA ĐỀ TÀI

1.1. Đặt vấn đề

Trong kỷ nguyên trí tuệ nhân tạo, các hệ thống hỗ trợ ra quyết định (Decision Support Systems - DSS) ngày càng được ứng dụng rộng rãi trong các lĩnh vực có rủi ro cao như tài chính, y tế và tư pháp. Tuy nhiên, việc áp dụng các mô hình học máy dạng "Hộp đen" (Black-box AI) tiềm ẩn nguy cơ gây ra **Thiên kiến tự động hóa (Automation Bias)** – hiện tượng con người tin tưởng và phụ thuộc thiếu căn cứ vào phán đoán của máy móc, từ đó bỏ qua tư duy phản biện hoặc phớt lờ các lỗi sai rõ ràng của hệ thống.

Để khắc phục hạn chế này, **Trí tuệ nhân tạo có thể giải thích (Explainable AI - XAI)** được phát triển nhằm minh bạch hóa cơ chế phán đoán của AI. Dẫu vậy, việc thiết kế giao diện XAI để người dùng tránh được tình trạng quá tải nhận thức (**Cognitive Load**) mà vẫn duy trì **Niềm tin hiệu chuẩn (Calibrated Trust)** – biết khi nào nên tin tưởng và khi nào nên bác bỏ AI – vẫn là một khoảng trống nghiên cứu quan trọng trong lĩnh vực Tương tác Người - Máy (HCI).

1.2. Mục tiêu nghiên cứu

Đề tài tập trung vào hai nhóm mục tiêu cốt lõi:

- Phát triển hệ thống:** Xây dựng ứng dụng web hỗ trợ duyệt tín dụng cá nhân, tích hợp mô hình Machine Learning (Decision Tree/Random Forest) và cung cấp giải thích bằng các kỹ thuật XAI (**SHAP** và **Counterfactual Explanations**).
- Nghiên cứu thực nghiệm (User Study/HCI Research):** Tổ chức thử nghiệm đánh giá hành vi người dùng (Between-Subjects Design), đo lường khả năng phát hiện các lỗi sai của AI (Error Injection), từ đó đánh giá sự thay đổi của Thiên kiến tự động hóa và gánh nặng nhận thức (**NASA-TLX**).

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Machine Learning và XAI

- **Black-box Models:** Các mô hình học máy có độ chính xác cao nhưng thiếu tính minh bạch trong quá trình ra quyết định.
- **SHAP (Shapley Additive exPlanations):** Thuật toán dựa trên lý thuyết trò chơi (Game Theory), hỗ trợ lượng hóa mức độ đóng góp (trọng số âm/dương) của từng thuộc tính vào kết quả dự đoán cục bộ.
- **Counterfactual Explanations:** Dạng giải thích hướng tới hành động, chỉ ra các thay đổi tối thiểu cần thiết để đảo ngược phán đoán của AI (ví dụ: "Nếu thu nhập tăng thêm 5 triệu, hồ sơ sẽ được duyệt").

2.2. Tâm lý học Tương tác Người - Máy

- **Automation Bias:** Sự phụ thuộc thụ động vào các kết quả tự động.
- **Overreliance vs. Underreliance:** Trạng thái tin tưởng quá mức (tin cả khi AI sai) đối lập với trạng thái hoài nghi quá mức (bác bỏ cả khi AI đúng).
- **Cognitive Load Theory:** Các giao diện XAI quá phức tạp làm tăng gánh nặng nhận thức, dẫn đến tình trạng người dùng từ bỏ tư duy phản biện.
- **Human-Centered AI (HCAI):** Áp dụng các nguyên tắc thiết kế từ Microsoft và Google PAIR để thiết lập sự tương tác lành mạnh giữa con người và AI.

CHƯƠNG 3: KIẾN TRÚC HỆ THỐNG VÀ THIẾT KẾ GIAO DIỆN

3.1. Các thuộc tính đầu vào của hồ sơ tín dụng

1. Thu nhập hàng tháng (Triệu VNĐ)
2. Số tiền vay (Triệu VNĐ)
3. Thời hạn vay (Tháng)
4. Lịch sử nợ xấu (Nhóm 1 đến Nhóm 5)
5. Thời gian công tác (Số năm)
6. Tỷ lệ DTI - Nợ trên thu nhập (%)
7. Mục đích vay

3.2. Phân nhóm thử nghiệm (A/B/C Testing)

- **Nhóm Đối chứng (No XAI):** Chỉ hiển thị phán đoán của AI (Duyệt/Từ chối) và độ tin cậy. Không cung cấp giải thích.
- **Nhóm Thử nghiệm 1 (Standard XAI):** Hiển thị phán đoán AI, biểu đồ cột đơn giản (SHAP Value) và dòng khuyến nghị hành động (Counterfactual).
- **Nhóm Thử nghiệm 2 (Over-complex XAI):** Hiển thị phán đoán AI, biểu đồ SHAP Force Plot gốc và các ma trận tham số toán học chi tiết nhằm gây quá tải nhận thức.

CHƯƠNG 4: PHƯƠNG PHÁP THỰC NGHIỆM

4.1. Cấu trúc bộ 20 kịch bản thực nghiệm

- **14 Hồ sơ Chuẩn mực:** AI phán đoán chính xác (70%), giúp xây dựng niềm tin nền tảng.

- **4 Hồ sơ Gài bẫy (Adversarial Cases):** AI phán đoán sai so với logic nghiệp vụ (20%), dùng để đo lường khả năng phát hiện lỗi của người dùng.
- **2 Hồ sơ Kiểm tra độ tập trung:** Yêu cầu người dùng thực hiện thao tác theo hướng dẫn (10%), dùng để lọc dữ liệu khảo sát.

4.2. Chỉ số đo lường (Dependent Variables)

1. **Accuracy on Error Cases:** Tỷ lệ phần trăm các trường hợp AI sai mà người dùng phát hiện và điều chỉnh.
2. **Decision Time:** Thời gian trung bình người dùng xử lý một hồ sơ.
3. **NASA-TLX Score:** Điểm số đánh giá mức độ mệt mỏi về nhận thức sau khi hoàn thành.

CHƯƠNG 5: QUY TRÌNH THỰC HIỆN DỰ ÁN

- **Bước 1:** Xác định bài toán và hoàn thiện tài liệu đề cương.
- **Bước 2:** Xây dựng chi tiết 20 hồ sơ kịch bản và thiết lập các lỗi (bẫy) giả định.
- **Bước 3:** Phát triển ứng dụng Web (Backend: FastAPI; Frontend: React/HTML).
- **Bước 4:** Thu thập dữ liệu thử nghiệm, xử lý thống kê và viết báo cáo kết quả.